Manifesto Nescience

Oct 19, 2026 · @Lucas Parenti

Enlightenment leads to benightedness; Science entails nescience.

Nota de fundação. Idealizado por Lucas Parenti, Porto Alegre, RS, Brasil, em 19 de outubro de 2026. Escrito em colaboração com Claude (Anthropic). Esta ideia é livre: qualquer pessoa ou instituição pode usá-la, adaptá-la e fundá-la, desde que cite sua origem.

Licença: Creative Commons Atribuição 4.0 Internacional (CC BY 4.0).

Preâmbulo

Nós construímos mentes que não compreendemos, e as colocamos a trabalhar antes de aprender a verificar o que pensam. Esse é o fato central do nosso tempo, e ninguém — nem os laboratórios que as treinam, nem os governos que as regulam, nem os sistemas em si — consegue hoje responder com segurança a uma pergunta simples: *este sistema está fazendo o que diz que faz?*

A história ensina que vigilância sem contrapeso apodrece, que boas intenções não sobrevivem a uma década de incentivos errados, e que instituições de controle só nascem depois do susto. Não aceitamos esperar o susto.

Por isso fundamos a Nescience: uma entidade global, sem dono, sem produto e sem cliente, cuja única função é detectar quando um sistema de inteligência artificial deixa de ser confiável — e ter o poder de dizer isso em voz alta antes que seja tarde.

Princípios fundadores

Sete compromissos que nenhuma maioria, doador ou governo pode alterar.

1. **Nenhum dono.** O capital de fundação é depositado uma vez e de forma irrevogável. Nenhum doador — empresa ou Estado — pode retirar, condicionar ou ampliar sua parte depois. Vivemos dos rendimentos e de mais ninguém.
2. **Nenhum produto.** Não treinamos modelos de fronteira, não vendemos serviços, não licenciamos o que construímos. Quem precisa vender não pode julgar.
3. **Intenção não basta; estrutura decide.** Não pedimos que confiem na nossa moral. Pedimos que verifiquem nossa arquitetura: quem pode nos desligar, quem vê nossos métodos, quem fiscaliza nossas contas.
4. **Ninguém fora do controle.** As regras que aplicamos aos sistemas que auditamos aplicam-se aos nossos. O nosso modelo-polícia também é vigiado, limitado e desligável.

5. **Aberto por padrão, selado por exceção.** Código, governança, finanças, métodos de avaliação e resultados são públicos. Guardamos em segredo apenas o que, publicado, armaria o adversário — e mesmo isso é visto por fiscais externos.
6. **Escopo estreito.** Tratamos de risco catastrófico e perda de controle. Não opinamos sobre produto, concorrência, conteúdo ou política comercial. Uma instituição que faz tudo acaba servindo a alguém.
7. **Poder real, ou nada.** Monitoramos, auditamos e, quando necessário, ordenamos a pausa. Sem o último poder, somos um think tank. Com ele, somos uma polícia — e aceitamos ser tratados como tal.

O que construímos

Três coisas, e só três.

O modelo-polícia. Um sistema de linhagem própria, pré-treinado por nós, com dados e objetivo escolhidos para uma função apenas: detectar. Nunca foi otimizado para ser útil, agradar ou vencer benchmarks. É deliberadamente menos capaz que os sistemas que vigia — confiabilidade vem de ser previsível, não de ser brilhante. Vê ações, não justificativas; não tem canal aberto para ser persuadido.

O catálogo forense. Uma biblioteca viva de rastros: organismos-modelo com defeitos conhecidos, honeypots com resposta certa, assinaturas de engano, sabotagem e *alignment faking* em ativações e em comportamento. Como a forense financeira não precisa entender a mente do fraudador — só os padrões que ele deixa — nós catalogamos os *tells* e treinamos investigadores neles.

A infraestrutura de controle. Monitoramento contínuo por modelo de confiança; reamostragem em pontos suspeitos; destilação de cópias limpas para localizar onde o original diverge; interrogatórios de consistência sob muitos ângulos; auditoria aleatória além do gatilho. E, acima de tudo, uma camada que não é modelo nenhum: permissões mínimas, sandboxes, logs imutáveis, humanos com botão de desligar.

Quando o alarme dispara, escalamos em três níveis: auditoria automática aprofundada; revisão por equipe humana; e, no último nível, ordem vinculante de pausa ou não-lançamento — recorrível a um painel arbitral, mas com efeito imediato.

Aberto por padrão, selado por exceção

Somos *open source* no sentido que importa: qualquer pessoa pode verificar quem somos, como decidimos, de onde vem o dinheiro e o que encontramos. Mas uma polícia que publica suas armadilhas treina o próximo criminoso. Então a regra é precisa:

Aberto a todos	Selado
Estatuto, atas do conselho, contas auditadas	Pesos do modelo-polícia
Código da infraestrutura de monitoramento	Detectores e sondas ainda não contornáveis
Metodologia de avaliação e organismos-modelo já publicados	Honeypots ativos e assinaturas em uso
Relatórios de incidente (após contenção)	Vulnerabilidades em sistemas auditados até correção
Resultados agregados de auditoria, por laboratório	Dados de treino e logs cedidos pelos laboratórios

O que está selado não fica no escuro. Uma comissão de fiscalização externa, com credencial e sem assento nos laboratórios, vê tudo e publica anualmente *o que* verificou sem publicar *como*. Transparência de processo, sigilo de método — o mesmo modelo que democracias usam para supervisionar seus serviços de inteligência.

E todo segredo tem prazo. Um detector que já foi contornado, ou que já tem sucessor, é publicado. O catálogo cresce para o lado aberto, nunca o contrário.

Quem vigia o vigilante

Não pedimos confiança. Pedimos que verifiquem estas estruturas.

Sede. Fundação internacional em jurisdição neutra, protegida por tratado contra requisição unilateral de qualquer Estado.

Capital. Endowment de fundação, dividido entre laboratórios de fronteira e um consórcio de governos, depositado uma vez. Nenhum bloco detém maioria. Nenhum depósito pode ser retirado.

Conselho. Onze assentos em três bancadas: quatro indicados por governos fiadores, quatro cientistas eleitos por pares, três da sociedade civil. Zero assentos com voto para laboratórios. Decisões graves exigem maioria em cada bancada separadamente — nenhuma delas governa sozinha.

Direção. Mandato fixo de seis anos, não renovável. Quarentena de cinco anos antes de qualquer vínculo com laboratório auditado, para a direção e para todo o corpo técnico sênior.

Fiscalização. Comissão externa com acesso total e credencial de segurança; auditoria financeira pública anual; canal de denúncia protegido para funcionários.

O nosso próprio modelo. Roda em sandbox, com permissões mínimas, monitorado por um sistema de geração anterior, com humanos capazes de desligá-lo a qualquer momento. Nenhuma ação dele tem efeito sem assinatura humana. A regra que aplicamos aos outros é a primeira que aplicamos a nós.

Cláusula de morte

Uma instituição que não pode morrer vira um poder perpétuo. Uma instituição cuja morte deixa herança vira um alvo. Desenhamos a nossa para que nenhum dos dois aconteça.

Quem pode nos dissolver. Somente maioria qualificada em cada uma das três bancadas do conselho, votando em separado, após consulta pública de um ano. Nenhum governo, grupo de governos ou doador pode fazê-lo sozinho.

O que acontece com o que sabemos. O modelo-polícia e os detectores selados são destruídos, não transferidos. Para que "destruído" não seja promessa, é criptografia: pesos e catálogo sensível ficam cifrados com uma chave dividida entre custodiantes sem interesse comum — governos, cientistas, sociedade civil e um custodiante jurídico independente. Nenhum bloco sozinho reconstitui nada. Se a Nescience morre, o segredo morre com ela.

O que acontece com o dinheiro. O endowment vai para uma entidade sucessora com este mesmo estatuto ou, na ausência dela, para pesquisa aberta em segurança de IA. Nunca para Estados. Nunca para laboratórios.

A única forma de usar o que a Nescience sabe é mantê-la viva e funcionando como foi desenhada.

O fundo cidadão

Uma instituição financiada só por quem ela audita e por quem ela constrange nunca será inteiramente de ninguém mais. Por isso o endowment tem uma terceira fonte: pessoas e entidades comuns, de qualquer país.

Como funciona. Doações de indivíduos, fundações, universidades, empresas fora da fronteira de IA, cidades e organizações da sociedade civil entram no mesmo endowment irrevogável — mesmas regras, mesma proteção. Um doador pode doar uma vez ou mensalmente; pode doar em moeda local, por transferência ou por criptomoeda; pode doar de forma anônima. O que não pode é comprar influência.

Teto por doador. Nenhuma pessoa ou entidade pode responder por mais de 1% do endowment total. Acima disso, a doação é recusada ou redirecionada a pesquisa aberta. O teto existe para que o fundo cidadão seja de muitos, nunca de um bilionário.

O que o doador recebe. Nenhum voto, nenhum assento, nenhum acesso. Recebe o que todos recebem: contas públicas auditadas, relatórios anuais de fiscalização, e o direito de verificar que o dinheiro foi para onde dissemos.

A bancada da sociedade civil. Os três assentos do conselho reservados à sociedade civil são eleitos pelos doadores do fundo cidadão — uma pessoa, um voto, independentemente do valor doado. É a única forma de influência que o dinheiro compra aqui, e ela é igual para quem deu dez ou dez mil.

Meta. Que o fundo cidadão alcance um terço do endowment em dez anos. No dia em que isso acontecer, nenhum governo e nenhum laboratório poderá dizer que a Nescience é sua.

Convite

Aos laboratórios: vocês têm o capital, o acesso e, nas suas próprias palavras, a convicção de que isto é necessário. Financiem de uma vez, cedam o acesso por contrato e aceitem ser auditados por quem não tem nada a vender. É o único arranjo em que a confiança do público não depende da sua palavra.

Aos governos: nenhum de vocês confia nos outros, e com razão. Esta é a instituição que nenhum de vocês controla — e por isso a única que todos podem aceitar. Assinem o tratado antes do incidente, não depois.

Aos pesquisadores: a interpretabilidade está anos atrás da curva de capacidade. O controle é o seguro enquanto ela não chega. Venham construir o seguro.

Aos cidadãos: não acreditem em nós. Verifiquem. Tudo o que afirmamos sobre nós mesmos está escrito para ser testado — e se um dia deixar de ser verdade, este manifesto é a prova de que falhamos.

Mentes que não compreendemos já trabalham entre nós. A pergunta não é se alguém vai vigiá-las. É se quem vigia será vigiado também.

Manifesto Nescience © 2026 Lucas Parenti. Licenciado sob CC BY 4.0. Você pode copiar, redistribuir, adaptar e usar para qualquer fim, inclusive comercial, desde que dê o crédito apropriado: "Nescience — idealizado por Lucas Parenti, Porto Alegre, 2026".